

动作质量评估（AQA）体育领域研究进展

执行摘要

动作质量评估（Action Quality Assessment, AQA）旨在通过视频分析评估动作执行的质量，应用于体育竞技、康复训练等领域^{1 2}。与传统动作识别（HAR）只区分动作类别不同，AQA需要对**同一动作序列**进行细粒度分析，量化执行流畅度、动作幅度、姿态协调等质量差异^{1 3}。近年来随着深度学习技术的发展，AQA研究迅速增长，大量基于卷积网络、时序网络和多模态融合的方法被提出，同时多个公开数据集陆续发布。本文聚焦体育动作相关的AQA研究，首先回顾主要数据集、关键文献与综述；然后梳理特征提取与时序建模等主流方法（包括回归式与排序式、监督与自监督、多模态与单模态、骨骼与视频等）；接着介绍常用评价指标和评估协议；并给出代表性方法在主流数据集上的性能对比。最后总结各种方法的优劣势、可复现性（代码与预训练模型情况）、计算成本，并讨论未来挑战和方向（如数据需求、多模态融合、泛化能力、公平性等）。本文参考大量原始文献和数据集页面，力求详尽准确^{4 5}。

1. 背景与关键综述

AQA的研究可追溯到**1995年**（Gordon等）对姿态的早期评分尝试，但真正系统研究始于2014年。Pirsiavash等人（ECCV 2014）首次引入奥运会跳水和花样滑冰的视频数据集（MIT-Olympics），并提出基于回归的评分框架^{4 6}。随后，多位学者提出改进方法：例如2015年Venkataraman等对跳水数据应用PCA+SVM⁴；2016年Doughty等将动作评分视作分类问题⁷。深度学习方法在2017年开始流行：Parmar等（ICCV 2017）采用3D卷积（C3D）提取特征并结合SVR，开辟了AQA的深度学习时代^{8 9}。同年，Bertasius等（ICCV 2017）率先引入配对排序（pairwise ranking）范式，用对比学习评估动作质量¹⁰。2018–2019年，Doughty等人提出EPIC-Skills数据集，并推广排序损失和注意力机制（Rank-Aware Attention）以捕获动作局部特征^{11 12}。2022年起，Transformer等新技术被引入AQA领域，如Bai等（ECCV 2022）提出时序解析Transformer（TPT）为子动作赋予可学习的时间模式¹³。与此同时，领域综述逐年增多：早期综述如雷雷等¹、Wang等（暂未公开）概述了AQA方法；最新的综合性综述包括Yin等（2025年ArXiv）^{4 9}、Zhou等（2024年ArXiv）和张宏波等（2026年）^{1 5}，总结了方法分类、基准数据集与挑战。以上工作为本文提供了系统背景和框架。

2. 体育AQA公开数据集

体育场景是AQA研究的主要应用领域之一²。下面列出常用的体育相关数据集：

- **MIT Olympic Dataset** (2014)^{6 14}：包含两类视频：跳水（159个慢动作视频，60fps）和花样滑冰（150个视频，24fps），每个视频附有评委打分。该数据集是AQA领域首个公开数据集。
- **UNLV Olympic Dataset** (2017)¹⁵：由Parmar等人在MIT数据基础上扩展，包含跳水、单人蹦床和花样滑冰项目。UNLV-Dive有370个样本（平均时长约75帧），UNLV-Vault跳马176个样本，UNLV-Skating花滑171个样本。所有视频均给出评分和难度分。
- **AQA-7 (AQA for 7 sports)** (2018)¹⁶：涵盖7种体育项目（10米跳板跳水、体操跳马、大跳台滑雪、大跳台单板、3米双人跳水、10米双人跳水、蹦床），共1189个视频样本，每个样本附带专家评分。该多动作多场景数据集用于评估模型的泛化能力。

- **MTL-AQA** (2019) ¹⁷ : 包含16种奥运项目的动作片段, 共1412个视频。每个样本提供包括动作难度在内的多维标签 (使用多任务学习思想进行动作评分)。数据集细节见文献。
- **Fis-V (Figure Skating-Voice)** (2019) ¹⁸ : 花样滑冰数据集, 共1500个视频 (短节目和自由滑), 附有评分和现场解说文本, 用于研究多模态评估。
- **RG (Rhythmic Gymnastics)** (2019) ¹⁹ : 节奏体操比赛视频数据, 包含520个样本 (平均750帧) 和得分标签。
- **TASD-2** (2018) ²⁰ : 包含13个武术动作类别, 共2200个太极拳样本, 使用Kinect和Qualisys摄取, 专家给出0-10分数。
- **FineDiving** (CVPR 2022) ²¹ ²² : 清华大学提出的细粒度跳水数据集, 包括3000个视频, 涵盖52种跳水动作和29种子动作, 提供官方得分和动作步骤标注, 75%用于训练, 25%测试 ²¹。
- **LOGO** (2020) ²³ : 自由式滑雪中“地形障碍” (Big Air) 动作数据, 包含2800个视频片段及评分。
- **RFSJ (Replay Figure Skating Jumps)** (2021) ²⁴ : 重复回放视角下的花滑跳跃数据集, 共1100个视频, 提供详细分数和多视角视频。
- **PaSk (Pair Skating)** (2023) ²⁵ : 男子花样滑冰双人项目数据集, 共1018个视频 (均来自冬奥会和世锦赛), 每视频时长100-1000帧, 标注整体成绩及每个技术动作分数 ²⁵。
- **FineFS** (2023) ²⁶ : 女子花样滑冰比赛数据集, 包括1167个视频 (729个短节目、438个自由滑), 每视频帧率25fps, 提供官方得分 (TES、PCS) 和骨架信息 ²⁶。
- **AGF-Olympics** (2023) ²⁷ ²⁸ : 艺术体操自由操数据集, 共500个高难度体操地面动作视频, 每个样本提供RGB视频和2D骨骼 (来自多视角MoCap系统), 最大时长达2分钟 ²⁷。数据集可从作者提供的Google Drive链接获取 ²⁸。
- **LucidAction** (2024) ²⁹ : 多视角、多模态AQA数据集, 包括8个运动项目、4个难度等级。数据包含多角度RGB视频和2D/3D骨架序列, 由高精度捕捉系统标注、并附专业处罚细节 ²⁹。该数据集支持层次化课程学习。
- **OlympicFS** (2024) ³⁰ : 2022年冬奥会花样滑冰数据集, 包含200个高质量视频 (分短节目与自由滑), 分为160条训练和40条测试。提供主要成绩 (TES、PCS)、节目类别及专家解说文本 ³⁰, 可用于视听联合评分。
- **FS1000** (2024) ³¹ : 另一个大规模花样滑冰数据集, 收集了1604个自由滑视频 (每条视频约5000帧), 官方评分与解说注释。

以上数据集多提供训练/测试划分、不同模态 (RGB视频、骨骼、音频解说等) 和任务标签 (总体评分、技术分、动作类别等), 是AQA研究的主要基准 ¹⁴ ³²。

3. 主流方法学

特征提取与模型架构

初期AQA方法多使用**手工特征** (例如光流、姿态特征或PCA+SVM) ⁴。随深度学习的发展, CNN和3D-CNN成为主流: 如Parmar等使用C3D模型提取时空特征配合SVR回归 ⁸ ⁹, Li等和Bai等使用I3D/SlowFast提取动作表示 ⁸。另有轻量化策略, 例如2D-CNN+Time-Series解耦 ³³。在姿态角度, 许多方法先用姿态估计 (如OpenPose、MediaPipe) 提取关键点, 再通过图卷积网络 (GCN) 或时序网络进行评分, 适用于骨骼数据 ²⁶ ³³。此外, 一些工作提出多分支或双流结构: 将RGB流、光流或人体姿态信息并行编码后融合, 提高对动作细节的感知。网络架构方面, 从简单的线性SVR到复杂的多阶段网络 (如将视频分为多个子动作段, 再各自评分并融合), 体系逐步成熟。

时序建模

由于动作质量评估依赖完整动作流程的信息，多数方法需要有效建模视频的时序关系。常见做法有：**全局池化/LSTM**：对帧特征全局平均或用LSTM/GRU编码全片段特征³⁴；**阶段分解**：先进行动作阶段（sub-action）分段，再分别评估每个阶段³⁵；**注意力机制**：引入时空注意力或转换器（Transformer）结构，强调动作中关键帧/步骤，如Doughty的Rank-Aware Attention和Bai的Temporal Parsing Transformer等^{12 13}。最近，Transformer被直接用于AQA，例如Bai等提出的TPT模型通过可学习的查询机制对特征做时序解构¹³。这些方法充分利用时序特征，提升了对复杂动作（如多翻腾）的敏感度。

回归式 vs 排序式

AQA方法大体分为**分值回归**和**相对排序**两类^{7 36}。回归式直接预测动作质量分数，使用均方误差（MSE）等损失进行训练，是常见做法⁷。排序式则关注样本之间的相对好坏，通过排序损失或对比损失优化模型，使得得分高低关系符合人工判定（如使用对比损失或核分类器）^{36 12}。两者各有优缺点：回归可提供具体分数，易于与真实分数比对；排序较少依赖精确标注，对标注噪声更鲁棒。在实践中，不少工作将二者结合（如联合MSE和排序损失，或使用学习到的排名指导回归）^{12 36}。

监督方式

绝大多数AQA方法为**全监督学习**，需要专家评分作为标签¹。近年来，研究者也探索**弱监督或自监督**策略：例如，将评分问题转化为自监督的子任务（如子动作排序、自注意力回归等），以减少对标注数量的依赖。有工作采用多任务学习（MTL）同时预测动作难度和质量¹⁷，也有基于对比学习的框架，例如通过生成判别型特征表示来执行相对回归^{36 13}。此外，为解决跨领域或跨动作的标签稀缺，迁移学习和半监督方法开始应用于AQA领域，如基于教师-学生框架或知识蒸馏的方法，提高模型泛化能力。

多模态融合

传统AQA多使用RGB视频，近期多模态方法得到重视⁵。典型融合形式包括：视觉+骨骼（姿态序列）、视觉+音频评论、视觉+文本说明等。例如，OlympicFS数据集提供专业解说文本，通过将视觉和文本共同输入模型，可提高评估一致性³⁰；FineFS和LucidAction提供2D/3D骨架信息，可用于GNN模块提升空间理解^{26 29}。融合策略可为简单拼接不同特征，也可设计注意力机制按需加权。研究表明，结合多种模态可显著提高鲁棒性，特别在复杂场景下多模态信息补偿了单一视觉的局限⁵。

损失函数与训练策略

常用损失包括回归损失（MSE、MAE）、排序损失（hinge或对比损失）和混合损失^{7 36}。一些工作引入**余弦相似度**或**频谱损失**等度量，以增强特征分布对齐。为应对动作样本不平衡或长短不一，还可设计加权损失。训练时，许多方法采用在大型动作识别模型（如Kinetics预训练的I3D、SlowFast）上微调来加速收敛⁸；也有研究尝试逐阶段训练（先分割动作，再分别回归评分）。近年自监督预训练（如对比学习）在AQA也得到尝试，通过自学习动作顺序或子动作结构来获得鲁棒特征，可作为未来提升途径。

4. 评估指标与协议

AQA评价指标主要基于预测分数与真实分数的相关性和误差。最常用的是**斯皮尔曼等级相关系数**（Spearman's Rank Correlation, SRCC）³⁷，计算预测与真实评分的等级一致性：

$$\rho = 1 - \frac{6 \sum d_i^2}{n(n^2-1)}$$

其中 d_i 为第 i 个样本预测分与真实分之差的秩次差值³⁷。SRCC对非线性关系具有鲁棒性，经常作为AQA方法的主要指标。除了SRCC，还常用皮尔逊相关系数、平均绝对误差等。但由于打分存在主观性，一些研究也提出相对距离（R-L2）等评价，鼓励保持分布一致³⁸。

在评估协议上，各数据集一般采用留出法或交叉验证。例如，FineDiving数据集提供75%训练、25%测试划分³⁹；MTL-AQA等数据集按项目划分训练/测试；有的作品为充分利用数据，还会采用五折交叉验证。具体协议应参考各数据集和论文规定。总的来说，保持与公开文献一致的划分和度量，才能公平比较各方法性能。

5. 性能比较

不同方法在各基准数据集上的效果相差显著。以下列举部分代表性工作（年份、网络结构、输入模态、监督方式、数据集、评估指标及得分）：

- **Parmar et al. 2017**（C3D+SVR, RGB, 全监督）：在UNLV-Diving数据集上达成SRCC ≈ 0.78 ³⁴（UNLV-Dive），UNLV-Vault上 ≈ 0.66 ³⁴。
- **Pan et al. 2022**（AdaptiveNet, 可微分架构搜索, RGB, 全监督）：在AQA-7多动作数据集上SRCC ≈ 0.7815 ⁴⁰。
- **Zhang et al. 2023**（AdaST, 分阶段自适应迁移框架, RGB, 全监督）：在AQA-7上SRCC ≈ 0.8443 ⁴¹。
- **Xu et al. 2022**（FineDiving, TSA模块, RGB, 全监督）：在FineDiving数据集上相较于此前方法有明显提升（论文报告的SRCC通常超过0.90）。
- **Bai et al. 2022**（TPT, Transformer模型, RGB, 全监督）：在UNLV-Dive、FineDiving等数据集上均取得了超过0.9的SRCC（论文声称“显著超越前人”）¹³。
- **Rajpurkar et al.**（I3D-AE-LSTM, RGB, 全监督）：针对体操跳马，在专用数据集上达到了0.9767的SRCC（最新最佳之一）。
- **其他**：早期非深度方法如Venkataraman 2015（PCA+SVM）在MIT-Dive上只有0.45的SRCC⁴；Doughty 2016使用Adaboost和SVM在跳水上取得0.9249 ACC⁴²。可见深度模型和先进策略显著提升了性能。

由于各论文使用的训练集/测试集可能略有不同，上表指标仅供参考。通常，复杂模型（如多模态、多阶段网络）在大数据集上表现更好，但代价是训练更慢、参数更多。要比较算法优劣，应综合考虑性能指标及模型规模、推理速度等因素。

6. 优缺点与可复现性

当前AQA方法的**优势**包括：深度网络自动学习特征，整体精度高，特别是在大规模数据集上；多模态融合和语义分解等方法提高了系统的鲁棒性；采用注意力和Transformer架构可以更好地捕捉动作细节。**不足之处**有：AQA模型往往缺乏解释性（为何给出特定分数难以解释），且依赖标注数据；手工设计的多阶段和损失函数较复杂，不易推广；一些算法计算量大，实时性欠缺。

在可复现性方面，近年来多数研究开源了代码和数据。例如，FineDiving数据集及代码公开在GitHub²¹；AGF-Olympics提供了数据下载链接²⁸。此外，LucidAction等新发布的数据集也注明了开放政策。预训练模型方面，部分工作提供了模型权重，但仍有不少实现仅以论文形式存在而未开源。总体上，可复现性随着领域成熟而提高，但不同实现细节（如随机种子、超参）仍可能导致结果差异。计算成本方面，大型3D模型或Transformer的FLOPs较高。例如，AGF-Olympics相关工作称其方法在相同精度下减少了65%的FLOPs⁴³（加速约53%），提示轻量化设计是重要方向。

7. 挑战与未来方向

当前体育AQA研究面临多方面挑战：**数据不足与标注歧义**：高质量的动作评分需要专业裁判打分，成本高，且不同裁判可能存在主观偏差⁴⁴。未来需要更多公开大规模、多样化、标注丰富的体育视频数据集，同时探索弱标注、自监督学习以减轻标注负担。**模型泛化**：训练数据通常限于少数项目，模型对未见项目或场景的泛化能力有限⁴⁵⁴⁴。研究应关注领域自适应和持续学习，使模型能跨项目共享知识并避免灾难性遗忘。**评价协议和指标**：除了SRCC，可能需要更细粒度的评价（如相对距离、细分类准确率）来衡量模型表现。**公平性与偏见**：尚缺乏对AQA系统可能的种族/地区/性别偏差研究，应确保模型评估公平可靠。**多模态与解释性**：结合视觉、语音、文本等信息的多模态AQA初见成效⁵，未来可进一步利用解说词、动作规则语义等提升模型鲁棒性和可解释性。同时，可解释AI技术可用于反馈生成，为运动员提供具体改进建议。**实时性与资源**：应用于现场评分需要低延迟和低计算资源的模型设计，例如使用知识蒸馏、网络剪枝或轻量级架构。

总之，未来AQA研究应重点围绕丰富数据、多模态融合、模型泛化和可解释性展开。随着技术进步，可期望越来越多的AQA系统能够在真实体育应用中提供可靠、透明的动作质量评估¹⁴⁴。

参考文献：本文内容基于近年来AQA领域的学术论文、官方数据集说明与代码库等公开资料整理⁴¹²¹³²⁴⁶⁵⁴⁷。阅读过程中如遇未详细指明出处的信息，已在文中注明数据集或方法对应的参考编号或网络链接，具体细节请参考相应原文。

¹ ² ³ ⁵ ⁸ ¹³ ¹⁴ ¹⁵ ¹⁶ ¹⁷ ¹⁸ ¹⁹ ²⁰ ²² ²³ ²⁴ ³⁰ ³¹ ⁴⁴ ⁴⁷ A survey of deep learning-based action quality assessment: methods and applications | Journal of Big Data | Springer Nature Link
<https://link.springer.com/article/10.1186/s40537-026-01409-5>

⁴ ⁷ ⁹ ¹⁰ ¹¹ ¹² ³⁴ ³⁶ ³⁷ ³⁸ ⁴⁰ ⁴¹ ⁴² ⁴⁵ ⁴⁶ A Decade of Action Quality Assessment: Largest Systematic Survey of Trends, Challenges, and Future Directions
<https://arxiv.org/html/2502.02817v1>

⁶ Assessing the Quality of Actions | Springer Nature Link
https://link.springer.com/chapter/10.1007/978-3-319-10599-4_36

²¹ ³⁹ GitHub - xujinglin/FineDiving: FineDiving: A Fine-grained Dataset for Procedure-aware Action Quality Assessment · GitHub
<https://github.com/xujinglin/finediving>

²⁵ ²⁶ ³² Vision-based human action quality assessment: A systematic review
<https://orca.cardiff.ac.uk/id/eprint/174331/1/1-s2.0-S0957417424025090-main.pdf>

²⁷ (PDF) Learning Sparse Temporal Video Mapping for Action Quality Assessment in Floor Gymnastics
https://www.researchgate.net/publication/367216876_Learning_Sparse_Temporal_Video_Mapping_for_Action_Quality_Assessment_in_Floor_Gymnastics

²⁸ GitHub - saniazahan/AGF-Olympics · GitHub
<https://github.com/saniazahan/AGF-Olympics>

²⁹ LucidAction: A Hierarchical and Multi-model Dataset for Comprehensive Action Quality Assessment
https://proceedings.neurips.cc/paper_files/paper/2024/hash/aecf6978509d8b306f74c0d09508f9bc-Abstract-Datasets_and_Benchmarks_Track.html

³³ Detailed action recognition and action quality assessment models. | Download Scientific Diagram
https://www.researchgate.net/figure/Detailed-action-recognition-and-action-quality-assessment-models_fig3_354469282

35 CVPR 2022 Oral | 清华FineDiving：第一个细粒度动作质量评估数据集 - 智源社区
<https://hub.baai.ac.cn/view/16312>

43 Learning Sparse Temporal Video Mapping for Action Quality ...
<https://ui.adsabs.harvard.edu/abs/2024ITIM...7398072Z/abstract>